


Wektor




Programista

Tablica wypełniona liczbami

```
array([1, 2, 3])
```


Fizyk

Obiekt opisywany za pomocą długości, kierunku i zwrotu.



Matematyk


Współrzędne punktu w przestrzeni.




Wektor – reprezentacja danych

$$\mathbf{p} = \begin{bmatrix} 64 \\ 131 \\ 23 \end{bmatrix} \begin{matrix} \text{height} \\ \text{weight} \\ \text{age} \end{matrix}$$


“p” for “patient”




$$cat = \begin{bmatrix} 0 \\ 0 \\ 2 \\ 0 \\ 15 \\ 1 \\ 0 \\ 0 \\ 51 \\ \vdots \\ 0 \end{bmatrix} \begin{matrix} \text{doc \#1} \\ \text{doc \#2} \\ \text{doc \#3} \\ \text{doc \#4} \\ \text{doc \#5} \\ \text{doc \#6} \\ \text{doc \#7} \\ \text{doc \#8} \\ \text{doc \#9} \\ \vdots \\ \text{doc \#1500} \end{matrix}$$



Tensor - przykład



Tensor - reprezentacja



9

```
array([ 9, -8,  5])
```

```
array([[ 4,  7, -4],  
       [-8,  4,  9],  
       [ 7,  6,  6]])
```

```
array([[[ 7,  0, -10],  
        [ 7, -2,  7],  
        [-3, -1, -8]],  
       [[-2,  8, -9],  
        [ 6,  6, -8],  
        [-9, -6, -6]],  
       [[-6, -7, -10],  
        [-2, -6,  6],  
        [ 0, -4,  4]]])
```

Mnożenie macierzy

$$\mathbf{X} = \begin{bmatrix} [5 & 6 & 1 & 2] \\ [8 & 7 & 6 & 3] \\ [5 & 0 & 6 & 4] \end{bmatrix}$$

$$\mathbf{Y} = \begin{bmatrix} [3 & 0 & 4 & 9] \\ [4 & 6 & 5 & 8] \\ [7 & 0 & 1 & 5] \end{bmatrix}$$

$$\mathbf{Z} = \mathbf{X} * \mathbf{Y} = \begin{bmatrix} [15 & 0 & 4 & 18] \\ [32 & 42 & 30 & 24] \\ [35 & 0 & 6 & 20] \end{bmatrix}$$

Każdy element macierzy X jest pomnożony przez odpowiadający mu element macierzy Y

$$x_{11} = 5 \quad y_{11} = 3 \quad z_{11} = x_{11} \times y_{11} = 15$$

$$x_{12} = 6 \quad y_{12} = 0 \quad z_{12} = x_{12} \times y_{12} = 0$$

$$X_{3 \times 4}$$

$$Y_{3 \times 4}$$

↔ Wymiar obu macierzy musi być taki sam

Mnożenie macierzy (algebraiczne) (*dot product*)

$$\mathbf{X} = \begin{bmatrix} [9 & 2 & 2] \\ [4 & 0 & 0] \\ [9 & 3 & 9] \end{bmatrix}$$


$$\mathbf{Z} = \mathbf{X} \cdot \mathbf{Y} = \begin{bmatrix} [104 & 29 & 41] \\ [32 & 4 & 4] \\ [162 & 63 & 105] \end{bmatrix}$$

$$\mathbf{Y} = \begin{bmatrix} [8 & 1 & 1] \\ [9 & 6 & 8] \\ [7 & 4 & 8] \end{bmatrix}$$

$$z_{11} = x_{11} \times y_{11} + x_{12} \times y_{21} + x_{13} \times y_{31}$$

$$z_{12} = x_{11} \times y_{12} + x_{12} \times y_{22} + x_{13} \times y_{32}$$

$$z_{21} = x_{21} \times y_{11} + x_{22} \times y_{21} + x_{23} \times y_{31}$$



$$B_{m \times q}$$

↔ *pierwszy wymiar* macierzy **A**
musi być taki sam jak *drugi wymiar*
macierzy **B**



The Matrix is everywhere. It is all around us. Even now, in this very room.

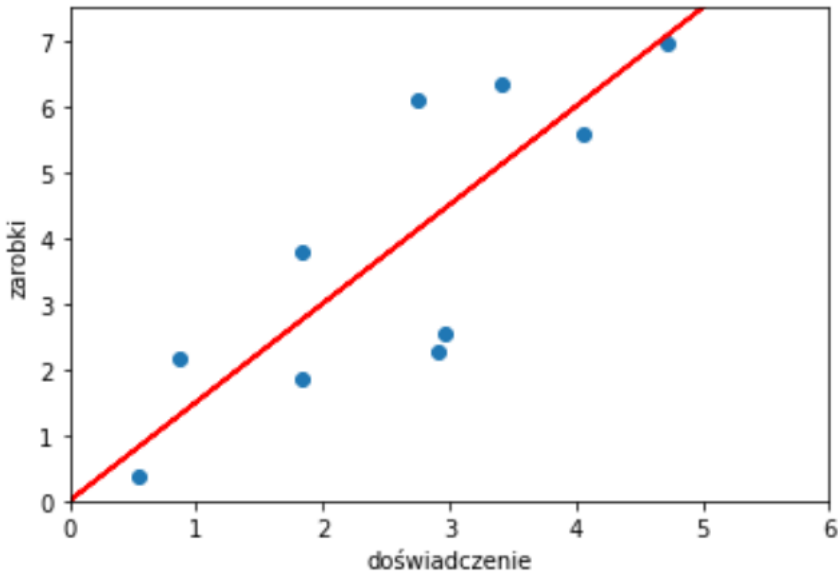
-Morpheus

Mnożenie macierzy (*geometria regresji*)

$$y = AX + b + e$$

$$\hat{y} = AX + b$$

$$\text{zarobki} = a \times \text{doświadczenie} + b$$



| b | doświadczenie | zarobki |
|---|---------------|----------|
| 1 | 4.057534 | 5.586908 |
| 1 | 2.750049 | 6.105262 |
| 1 | 2.964347 | 2.533063 |
| 1 | 3.410334 | 6.332447 |
| 1 | 1.828527 | 1.840721 |
| 1 | 0.548475 | 0.355877 |
| 1 | 0.876145 | 2.176086 |
| 1 | 4.729183 | 6.966537 |
| 1 | 1.834105 | 3.784180 |
| 1 | 2.904804 | 2.281207 |

$$\begin{aligned} \text{zarobki}_1 &= a \times \text{doświadczenie}_1 + b \\ \text{zarobki}_2 &= a \times \text{doświadczenie}_2 + b \\ \text{zarobki}_3 &= a \times \text{doświadczenie}_3 + b \\ &(\dots) \end{aligned}$$

| b doświadczenie | | * współczynniki = | = | zarobki | |
|--------------------|----------|-------------------------|---|----------------|----------|
| 1 | 4.057534 | | | a_1 * 4.06 + b | 5.586908 |
| 1 | 2.750049 | | | a_2 * 2.75 + b | 6.105262 |
| 1 | 2.964347 | | | a_3 * 2.96 + b | 2.533063 |
| 1 | 3.410334 | | | a_4 * 3.41 + b | 6.332447 |
| 1 | 1.828527 | | | a_5 * 1.83 + b | 1.840721 |
| 1 | 0.548475 | | | a_6 * 0.55 + b | 0.355877 |
| 1 | 0.876145 | | | a_7 * 0.88 + b | 2.176086 |
| 1 | 4.729183 | | | a_8 * 4.73 + b | 6.966537 |
| 1 | 1.834105 | | | a_9 * 1.83 + b | 3.784180 |
| 1 | 2.904804 | | | a_10 * 2.9 + b | 2.281207 |

Mnożenie macierzy (reprezentacja regresji)

$y = AX + b, \quad b = 0 \quad y = AX$

$X =$

| długość | szerokość | wysokość |
|------------|------------|------------|
| 79.564798 | 139.113256 | 165.247195 |
| 67.174099 | 47.367705 | 286.349772 |
| 118.450682 | 10.869266 | 83.118642 |
| 14.156648 | 25.846663 | 189.236549 |
| 200.551913 | 95.144694 | 37.003291 |
| 63.339889 | 99.574222 | 137.854002 |
| 156.675029 | 204.190017 | 16.619945 |

$y =$


| opóźnienie |
|------------|
| 0.601009 |
| 3.031186 |
| 4.160437 |
| 1.326778 |
| 3.453975 |
| 1.106210 |
| 0.091691 |

$A =$

| współczynniki |
|---------------|
| a_1 |
| a_2 |
| a_3 |

| współczynniki |
|---------------|
| a_1 |
| a_2 |
| a_3 |

$op\acute{o}znienie = a_1 \times dlugosc + a_2 \times szerokosc + a_3 \times wysokość$



$y = AX =$

| długość | szerokość | wysokość | opóźnienie |
|------------|------------|------------|------------|
| 79.564798 | 139.113256 | 165.247195 | 0.601009 |
| 67.174099 | 47.367705 | 286.349772 | 3.031186 |
| 118.450682 | 10.869266 | 83.118642 | 4.160437 |
| 14.156648 | 25.846663 | 189.236549 | 1.326778 |
| 200.551913 | 95.144694 | 37.003291 | 3.453975 |
| 63.339889 | 99.574222 | 137.854002 | 1.106210 |
| 156.675029 | 204.190017 | 16.619945 | 0.091691 |


Metoda najmniejszych kwadratów

$$Y = \beta X + e$$

$$\hat{Y} = \beta X$$


$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

$$\mathbf{X} = \begin{pmatrix} x_{1,0} & x_{1,1} & \dots & x_{1,p-1} \\ x_{2,0} & x_{2,1} & \dots & x_{2,p-1} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,0} & x_{n,1} & \dots & x_{n,p-1} \end{pmatrix}.$$



$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Prawdopodobieństwo



$$P(A) = \frac{|A|}{|\Omega|}$$

$$\mathbb{P}(\emptyset) = 0,$$


$$A \subset B \rightarrow \mathbb{P}(A) \leq \mathbb{P}(B),$$

$$0 \leq \mathbb{P}(A) \leq 1,$$


$$\mathbb{P}(A^C) = 1 - \mathbb{P}(A),$$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

Prawdopodobieństwo warunkowe



Prawdopodobieństwo całkowite



$$\begin{aligned} P(A) = & P(A|B1)P(B1) \\ & + P(A|B2)P(B2) \\ & + P(A|B3)P(B3) \\ & + P(A|B4)P(B4) \\ & + P(A|B5)P(B5) \\ & + P(A|B6)P(B6) \end{aligned}$$

$$P(\Omega) = P(B1) + P(B2) + P(B3) + P(B4) + P(B5) + P(B6)$$

Twierdzenie Bayesa

przykład praktyczny (prawdopodobieństwo choroby)

Dany jest test o wrażliwości 80%, co oznacza, że jeśli choroba występuje to test będzie pozytywny z prawdopodobieństwem 0.8.

Prawdopodobieństwo wystąpienia choroby to 0.004.

Test zwraca 10% fałszywie pozytywnych wyników.

$$P(test_{pozytywny} | pacjent_{chory}) = 0.8$$

$$P(pacjent_{chory} | test_{pozytywny}) = ?$$

$$P(pacjent_{chory}) = 0.004$$

$$P(test_{pozytywny} | pacjent_{zdrowy}) = 0.1$$

$$P(pacjent_{chory} | test_{pozytywny}) = \frac{P(test_{pozytywny} | pacjent_{chory})P(pacjent_{chory})}{P(test_{pozytywny})}$$

$$= \frac{P(test_{pozytywny} | pacjent_{chory})P(pacjent_{chory})}{P(test_{pozytywny} | pacjent_{chory})P(pacjent_{chory}) + P(test_{pozytywny} | pacjent_{zdrowy})P(pacjent_{zdrowy})}$$

$$= \frac{0.8 \times 0.004}{0.8 \times 0.004 + 0.1 \times 0.996} = 0.031$$

Twierdzenie Bayesa

$P(\text{test}_{\text{pozytywny}} | \text{pacjent}_{\text{chory}}) = 0.8$

$P(\text{pacjent}_{\text{chory}}) = 0.004$

$P(\text{test}_{\text{pozytywny}} | \text{pacjent}_{\text{zdrowy}}) = 0.1$

● ilość osób: 10 000

■ ilość osób chorych:
 $10\,000 * P(\text{pacjent}_{\text{chory}}) = 40$

■ ilość osób chorych z pozytywnym wynikiem:
 $40 * P(\text{test}_{\text{pozytywny}} | \text{pacjent}_{\text{chory}}) = 32$

■ ilość osób zdrowych z pozytywnym wynikiem:
 $9\,960 * P(\text{test}_{\text{pozytywny}} | \text{pacjent}_{\text{zdrowy}}) = 996$


■ ilość osób z pozytywnym wynikiem:
 $996 + 32 = 1\,028$

*Jakie jest prawdopodobieństwo wylosowanie osoby chorej
wśród wszystkich osób z pozytywnym wynikiem testu?*

$$P(\text{pacjent}_{\text{chory}} | \text{test}_{\text{pozytywny}}) = \frac{32}{1028} = \mathbf{0.031}$$

Twierdzenie Bayesa

przykład praktyczny (Naïve Bayes)



$$P(dom|x) = \frac{P(x|dom)P(dom)}{P(x)}$$

$$P(mieszkanie|x) = \frac{P(x|mieszkanie)P(mieszkanie)}{P(x)}$$

$$P(dom) = \frac{|dom|}{|obserwacje|} = \frac{20}{30}$$

$$P(x|dom) = \frac{|dom \text{ w otoczeniu}|}{|dom|} = \frac{1}{20}$$

$$\begin{aligned} P(x) &= P(x|dom)P(dom) \\ &\quad + P(x|mieszkanie)P(mieszkanie) \\ &= \frac{1}{20} \frac{20}{30} + \frac{4}{10} \frac{10}{30} = \frac{4}{30} \end{aligned}$$

$$P(dom|x) = 0.25$$

Zmienna Losowa

Zmienna losowa to funkcja:

$$X: \Omega \longrightarrow E \subset \mathbb{R}$$

$$\Omega = \left\{ \begin{array}{c} \text{obverse of 2 zł coin} \\ \text{reverse of 2 zł coin} \end{array} \right\}$$



→ 1



→ 0

Funkcja Prawdopodobieństwa (rozkład zmiennej losowej)


Probability density function (PDF)

$$f_X(x) = P(X = x)$$




$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

$$P(X = 1) = \frac{1}{6} \quad P(X = 2) = \frac{1}{6} \quad P(X = 3) = \frac{1}{6} \quad (\dots)$$



np. rozkład normalny




Dystrybuanta

Cumulative distribution function (CDF)

$$F_X(x) = P(X \leq x)$$

Każda dystrybuanta $F(x)$ jest funkcją

- niemalejącą,
- dążącą do 1 dla $x \rightarrow +\infty$,
- dążącą do 0 dla $x \rightarrow -\infty$,
- prawostronnie ciągłą,
- posiadającą lewostronne granice,
- różniczkowalną prawie wszędzie.



Dystrybuanta

Cumulative distribution function (CDF)

$$F_X(x) = P(X \leq x)$$



$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

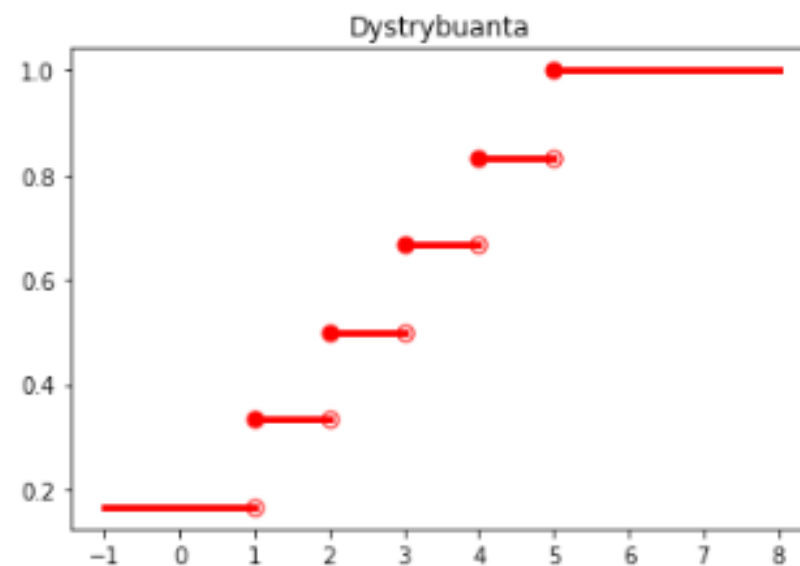
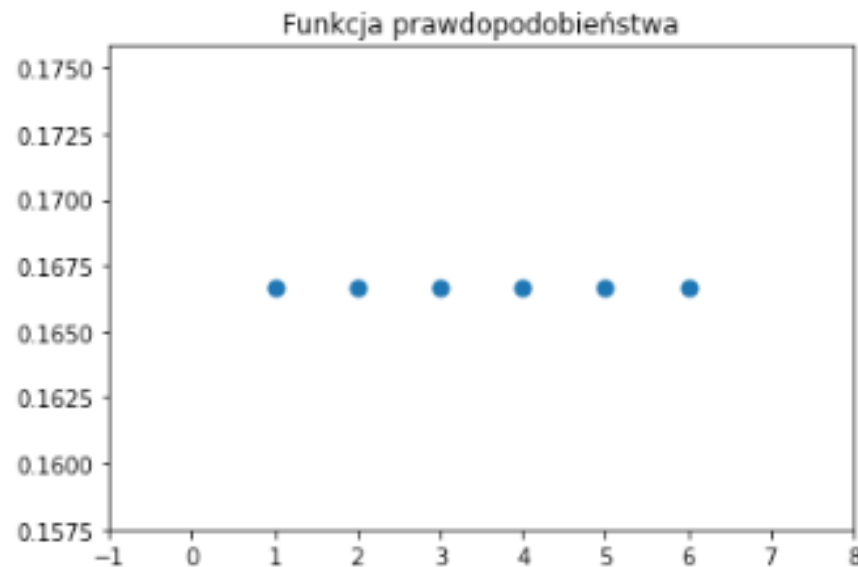
$$P(X = 1) = \frac{1}{6} \quad P(X = 2) = \frac{1}{6} \quad P(X = 3) = \frac{1}{6} \quad (\dots)$$

$$P(X \leq 1) = P(X = 1) = \frac{1}{6}$$

$$P(X \leq 2) = P(X = 1) + P(X = 2) = \frac{2}{6}$$

$$P(X \leq 3) = P(X = 1) + P(X = 2) + P(X = 3) = \frac{3}{6}$$

$$P(X \leq \mathbf{3.42}) = P(X = 1) + P(X = 2) + P(X = 3) = \frac{3}{6} \quad (\dots)$$



Parametry opisujące rozkłady

Wartość oczekiwana

Dyskretna zmienna losowa

$$E[X] = \sum_{i=1}^{\infty} x_i p_i,$$

Ciągła zmienna losowa

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx.$$


Wartość oczekiwaną nazywamy spodziewany wynik doświadczenia losowego przy założonym prawdopodobieństwie jego wystąpienia.

Wariancja

$$\begin{aligned} \text{Var}(X) &= E[(X - E[X])^2] \\ &= E[X^2 - 2X E[X] + E[X]^2] \\ &= E[X^2] - 2E[X] E[X] + E[X]^2 \\ &= E[X^2] - E[X]^2 \end{aligned}$$


Wariancja jest podstawową miarą zmienności zmiennej losowej. Wariancja informuje o tym, jak duże jest zróżnicowanie wyników w danym zbiorze wyników (zmiennej).

Rozkład normalny – reguła trzech sigm



Case study: *Dopancerznie* samolotów

https://en.wikipedia.org/wiki/Survivorship_bias#In_the_military



The red dots indicate areas of combat damage received by surviving WWII bombers. Where would you add armor to increase survivability? The statistician Abraham Wald recommended reinforcing the areas *without* damage. Since these data came from surviving aircraft only, bombers hit in undotted areas were the ones that did not make it back.

Case study: Produkcja czołgów

An empirical Approach to Economic Intelligence in World War II,
Journal of the American Statistical Association, Vol. 42, No. 237
(Mar., 1947), pp. 72–91.

https://en.wikipedia.org/wiki/German_tank_problem



Produkcja czołgów (dane historyczne):

| Miesiąc | est. statystyków | est. agentów | dane prod. |
|---------------|------------------|--------------|------------|
| Czerwiec 1940 | 169 | 1000 | 122 |
| Czerwiec 1941 | 244 | 1550 | 271 |
| Sierpień 1942 | 327 | 1550 | 342 |

Paradoks Simpsona


Przyjęci na studia (Univ. of California, Berkeley)

| | Zgłoszeń | Przyjętych |
|-----------|----------|------------|
| Mężczyźni | 2691 | (1198) 45% |
| Kobiety | 1835 | (614) 33% |


Przyjęci z podziałem na kierunki

| K. | Mężczyźni | | Kobiety | |
|----|-----------|------------|----------|------------|
| | Zgłoszeń | Przyjętych | Zgłoszeń | Przyjętych |
| A | 825 | (512) 62% | 108 | (89) 82% |
| B | 560 | (353) 63% | 25 | (17) 68% |
| C | 325 | (120) 37% | 593 | (219) 37% |
| D | 417 | (138) 33% | 375 | (131) 35% |
| E | 191 | (53) 28% | 393 | (134) 34% |
| F | 373 | (22) 6% | 341 | (24) 7% |


Wybieramy koszyk, z koszyka losujemy kulę, wygrywa zielona.
Który koszyk wybrać?




$$\frac{5}{11} > \frac{3}{7}$$





A teraz?



$$\frac{6}{9} > \frac{9}{14}$$



A jak połączymy zawartość koszyków?




Wariancja

✓
0s



```
N1 = np.random.normal(loc=0.0, scale= 0.5, size=100_000)
N2 = np.random.normal(loc=0.0, scale= 3.0, size=100_000)
N3 = np.random.normal(loc=0.0, scale=10.0, size=100_000)
plt.figure(figsize=(10, 5))
plt.hist(N3, bins=50, alpha=0.3, color='blue')
plt.hist(N2, bins=50, alpha=0.3, color='green')
plt.hist(N1, bins=50, alpha=0.3, color='red')
plt.show()
```



Podstawowe statystyki – wzory!

wartość
oczekiwana:

$$\mathbb{E}X = \sum_{i=1}^n x_i p_i$$

wariancja:

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + \mathbb{E}[X]^2 \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2\end{aligned}$$

odchylenie
standardowe:

$$\begin{aligned}\sigma(X) &= \sqrt{\mathbb{E}[(X - \mathbb{E}[X])^2]} \\ &= \sqrt{\mathbb{E}[X^2] - (\mathbb{E}[X])^2}\end{aligned}$$

kowariancja: $\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X) \cdot (Y - \mathbb{E}Y)]$.

Współczynnik
korelacji Pearsona :

$$r_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

statystyka:

Wariancja populacji:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Wariancja próbki:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Wariancja-znana średnia:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

\bar{x} – średnia

μ – wartość oczekiwana

Współczynnik korelacji Pearsona

współczynnik określający poziom zależności liniowej między zmiennymi losowymi

